

MODELO DE PREDICCIÓN DEL PRECIO DE CIERRE DE BITCOIN

Fecha: 17 de junio de 2026.

Asunto: Resumen ejecutivo de experimentación y modelado para predicción del bitcoin a 7 días.

Alumno: Demaria Angelo.

Descripción de los Datos

Fuente de Datos: Se utilizó el precio de bitcoin histórico sacado de la api de Yahoo Finance y el índice Fear & Greed. Este índice mide el sentimiento del mercado de criptomonedas en una escala de 0 a 100.

- Este índice se divide en 5 escalas:
 - **0 a 24 (Miedo Extremo):** Los inversores están demasiado asustados, lo que suele provocar ventas masivas e irracionales.
 - **25 a 49 (Miedo):** El mercado muestra preocupación sobre el futuro de los precios.
 - **50 (Neutral):** No hay una emoción dominante clara.
 - **51 a 74 (Codicia / Avaricia):** El entusiasmo crece; los inversores compran ante la expectativa de mayores ganancias.
 - **75 a 100 (Codicia Extrema):** Existe euforia y un riesgo inminente de que el mercado esté sobrecalentado, anticipando una posible corrección.
- Filtrado Temporal (Criterio de Selección): Se tomó la decisión estratégica de recortar el dataset y utilizar únicamente el periodo comprendido desde 01/02/2018 hasta la actualidad (17/06/2026). Se descartaron los años anteriores para eliminar el "ruido" asociado a la inmadurez temprana del mercado cripto, y además de poder relacionarlo con los datos del índice ya que este tiene datos a partir del 01/02/2018. Además de centrar el aprendizaje del modelo en el comportamiento institucional y macroeconómico más reciente.

Variables de entrada:

- OHLCV (Base): Variables crudas de mercado (**O**pen, **H**igh, **L**ow, **C**lose, **V**olume).
- Ingeniería de Features (Indicadores Técnicos): Se generaron variables derivadas para enriquecer el contexto del modelo:
 - Tendencia: Medias Móviles Simples (SMA) de 7 y 30 días para suavizar ruido y detectar tendencias a corto/mediano plazo.
 - Memoria (Lags): Variables de rezago (Pct_Change) para entregar explícitamente el valor del día anterior.
 - Volatilidad: Desviación estándar móvil de 30 días (Rolling_volatility_30) para medir la dispersión del precio.
- Mejoras Potenciales: La principal mejora es la adicción de las variables del índice Fear & Greed.

Detalle del Preprocesamiento:

1. Limpieza y preparación de datos

El preprocesamiento comenzó con una depuración inicial de los registros históricos de Bitcoin y del índice Fear & Greed, con el objetivo de asegurar consistencia temporal y calidad numérica antes del modelado.

En primer lugar, se eliminaron filas no válidas y se transformaron los tipos de datos: la variable de fecha se convirtió a formato datetime y las variables de mercado (precio de apertura, cierre, máximo, mínimo y volumen) se convirtieron a tipo numérico. Durante este proceso, cualquier valor inválido fue transformado en nulo para facilitar su posterior tratamiento.

Luego se construyeron variables derivadas relevantes para capturar dinámica financiera y tendencia, entre ellas:

- Cambio diario (cierre menos apertura).
- Volatilidad diaria (máximo menos mínimo).
- Variación porcentual del cierre y del volumen.
- Medias móviles de 7 y 30 días.
- Volatilidad móvil en ventana de 30 días.
- Variables rezagadas del precio de cierre.

Para el índice Fear & Greed, se estandarizó la columna de fecha, se normalizó su formato y se ordenó cronológicamente. Posteriormente, se generaron variables complementarias como diferencia diaria, medias móviles y señal de tendencia del sentimiento.

Ambas fuentes se integraron mediante una unión temporal asof con dirección hacia atrás. Esta decisión metodológica evita usar información futura al completar observaciones y reduce riesgo de fuga de datos temporal.

Además, se incorporaron variables de contexto estructural del mercado cripto vinculadas al halving, incluyendo indicador del evento y recompensa por bloque según período histórico.

Finalmente, para el entrenamiento supervisado, se generaron objetivos futuros de precio para horizontes de 1 a 7 días y se eliminaron filas con valores nulos remanentes, especialmente las observaciones finales que no tienen etiqueta futura por construcción.

2. Escalado de variables

Una vez definidos predictores y objetivos, se aplicó escalado mediante estandarización *z-score*, transformando cada variable de entrada para que tenga media cercana a 0 y desvío estándar cercano a 1.

El escalado se implementó dentro de un pipeline de entrenamiento, de modo que en cada fold de validación temporal el transformador se ajusta exclusivamente

con datos del tramo de entrenamiento y luego se aplica al tramo de validación. Esta estrategia preserva la causalidad temporal y evita contaminación de información entre particiones (folds).

Modelos y Experimentación

Modelos evaluados:

Se compararon tres enfoques con distinta complejidad y sesgo inductivo:

- Regresión Lineal, Random Forest Regressor y K-Nearest Neighbors (KNN) con un $k = 25$
- Para asegurar compatibilidad con predicción multisalida, se incluyó una verificación automática: cuando un modelo no soporta múltiples salidas de forma nativa, se encapsula con MultiOutputRegressor.


3. Estrategia de validación temporal

La evaluación se realizó con validación cruzada para series temporales (TimeSeriesSplit, 5 particiones), preservando el orden cronológico y evitando mezcla entre pasado y futuro.

Evaluación de modelos

Aunque se evaluaron modelos más complejos, la regresión lineal obtuvo el menor error. Esto se debe a que las variables utilizadas (SMA, lags, volatilidad y RSI) tienen relaciones mayormente lineales con el precio de cierre y a que la cantidad de datos era limitada, lo cual dificulta el rendimiento de modelos como Random Forest. Por su simplicidad y menor riesgo de sobreajuste, la regresión lineal logró generalizar mejor y alcanzó el mejor desempeño.

Comparación de métricas por modelo



Conclusión

La experimentación mostró que combinar variables de mercado de Bitcoin con señales de sentimiento mejora la capacidad de pronóstico en horizontes cortos.

El uso de validación temporal y pipeline de escalado permitió evaluar los modelos de forma realista y sin fuga de información.

En términos generales, los resultados evidencian que los enfoques no lineales tienden a

capturar mejor la dinámica del precio que los modelos más simples, aunque todos degradan su precisión a medida que aumenta el horizonte de predicción. Como línea futura, conviene profundizar el ajuste de hiperparámetros y ampliar variables exógenas para mejorar robustez y estabilidad.