

| INTELIGENCIA ARTIFICIAL – UCSE |

## MODELO DE PREDICCIÓN DEL PRECIO DE CIERRE DE BITCOIN

Fecha: 1 de septiembre de 2026.

Asunto: Resumen ejecutivo de experimentación y modelado para predicción del bitcoin a 7 días.

Alumno: Demaria Angelo.

## Descripción de los Datos

Fuente de Datos: Se utilizó el precio de bitcoin histórico sacado de la api de Yahoo Finance y el índice Fear & Greed. Este índice mide el sentimiento del mercado de criptomonedas en una escala de 0 a 100.

Este índice se divide en 5 escalas:

- **0 a 24 (Miedo Extremo):** Los inversores están demasiado asustados, lo que suele provocar ventas masivas e irracionales.
  - **25 a 49 (Miedo):** El mercado muestra preocupación sobre el futuro de los precios.
  - **50 (Neutral):** No hay una emoción dominante clara.
  - **51 a 74 (Codicia / Avaricia):** El entusiasmo crece; los inversores compran ante la expectativa de mayores ganancias.
  - **75 a 100 (Codicia Extrema):** Existe euforia y un riesgo inminente de que el mercado esté sobrecalentado, anticipando una posible corrección.
- Filtrado Temporal (Criterio de Selección): Se tomó la decisión estratégica de recortar el dataset y utilizar únicamente el periodo comprendido desde 01/02/2018 hasta la actualidad (31/08/2026). Se descartaron los años anteriores para eliminar el "ruido" asociado a la inmadurez temprana del mercado cripto, y además de poder relacionarlo con los datos del índice ya que este tiene datos a partir del 01/02/2018. Además de centrar el aprendizaje del modelo en el comportamiento institucional y macroeconómico más reciente.

### Variables de entrada:

- OHLCV (Base): Variables crudas de mercado (Open, High, Low, Close, Volume).
- Ingeniería de Features (Indicadores Técnicos): Se generaron variables derivadas para enriquecer el contexto del modelo:
  - Tendencia: Medias Móviles Simples (SMA) de 7 y 30 días para suavizar ruido y detectar tendencias a corto/mediano plazo.
- Memoria (Lags): Variables de rezago (Pct\_Change) para entregar explícitamente el valor del día anterior.
- Volatilidad: Desviación estándar móvil de 30 días (Rolling\_volatility\_30 y Rolling\_volatility\_7) para medir la dispersión del precio.
- Mejoras Potenciales: La principal mejora es la adicción de las variables del índice Fear & Greed.

## **Detalle del Preprocesamiento**

### **1. Limpieza y preparación de datos:**

El preprocesamiento comenzó con una depuración inicial de los registros históricos de Bitcoin y del índice Fear & Greed, con el objetivo de asegurar consistencia temporal y calidad numérica antes del modelado.

En primer lugar, se eliminaron filas no válidas y se transformaron los tipos de datos: la variable de fecha se convirtió a formato datetime y las variables de mercado (precio de apertura, cierre, máximo, mínimo y volumen) se convirtieron a tipo numérico. Durante este proceso, cualquier valor inválido fue transformado en nulo para facilitar su posterior tratamiento.

Luego se construyeron variables derivadas relevantes para capturar dinámica financiera y tendencia, entre ellas:

- Cambio diario (cierre menos apertura).
- Volatilidad diaria (máximo menos mínimo).
- Variación porcentual del cierre y del volumen.
- Medias móviles de 7 y 30 días.
- Volatilidad móvil en ventana de 7 y 30 días.
- Variables rezagadas del precio de cierre.

Para el índice Fear & Greed, se estandarizó la columna de fecha, se normalizó su formato y se ordenó cronológicamente. Posteriormente, se generaron variables complementarias como diferencia diaria, medias móviles y señal de tendencia del sentimiento.

Ambas fuentes se integraron mediante una unión temporal asof con dirección hacia atrás. Esta decisión metodológica evita usar información futura al completar observaciones y reduce riesgo de fuga de datos temporal.

Además, se incorporaron variables de contexto estructural del mercado cripto vinculadas al halving, incluyendo indicador del evento y recompensa por bloque según período histórico.

Finalmente, para el entrenamiento supervisado, se generaron objetivos futuros de precio para horizontes de 1 a 7 días y se eliminaron filas con valores nulos remanentes, especialmente las observaciones finales que no tienen etiqueta futura por construcción.

### **Modelos y Experimentación**

Se realizaron 2 experimentos en los cuales se fueron evaluando distintos hiper parámetros en cada uno. Para el primero se evaluaron distintos parámetros para KNN y Random Forest, y también se utilizó la regresión lineal.

Para KNN se probó con 5, 11, 21, 31, 41 vecinos y para Random Forest, se evaluó con 50, 100, 200 árboles de decisión, además de la profundidad máxima de cada árbol, los

posibles valores que pueden tomar son 50, 100 , 200.

Y se llegó a la conclusión que los modelos que menos error dieron fueron:

- KNN: con 21 vecinos (MAPE=13.35%)
- RandomForest: con 200 árboles de decisión y sin profundidad máxima para cada árbol. (MAPE=12.46%)

Estos porcentajes de error se compararon con los devuelto con la regresión lineal la cual arrojó un error de 4.88%. Por ende, se decidió utilizar este modelo.

En el segundo experimentó se decidió utilizar una red neuronal la cual se fue probando con distintos valores posibles para las capas ocultas, dropout, learning rate, el tamaño del batch para entrenar, la mejor configuración que devolvió el menor error fue la siguiente combinación:

Capas ocultas (128, 128, 64), Dropout: 0.0, Learning Rate: 0.01 y Batch Size: 16

Error obtenido: MAE: 1735.64 y RMSE: 2308.7

En base a los experimentos, se eligió la configuración que menos error arrojó tanto para la regresión lineal como para la red neuronal.

### 3. Estrategia de validación temporal

La evaluación se realizó con validación cruzada para series temporales (TimeSeriesSplit, 7 particiones), preservando el orden cronológico y evitando mezclar entre pasado y futuro.

## Evaluación de modelos

El primer modelo que se utilizó fue la regresión lineal el cual se divido en 7 fold para evaluar el modelo. En proporción se utilizó el 80% para test y 20% para validación. El error de la regresión lineal es un **MAE 1622.90, RMSE 2664.91 y MAPE 4.72%.**

El segundo modelo, a comparación con el modelo de regresión lineal esté mantiene un error relativamente pequeño del 2% en el horizonte t+1 y 6% en el t+7. Este modelo tiene una sola salida, una por cada horizonte, en síntesis, se entrenan 7 modelos para predecir cada una de las salidas. En cambio, el primer modelo (Regresión lineal) es un modelo de múltiple salida.

Ambos modelos guardan las predicciones del btc en un csv aparte.

## Conclusión

Ambos modelos logran un error relativo similar para el corto plazo (2 a 5% de MAPE), pero difieren en robustez: la Regresión Lineal Final es un único modelo multi-salida, simple y estable en todos los horizontes (MAPE 5% aprox en la validación. La Red Neuronal Final, compuesta por 7 modelos independientes (uno por horizonte), cuenta con una evaluación sobre datos que fueron separados antes de armar cada fold, estos

datos abarcan desde las fechas 2025-05-07 al 2026-08-17, mostrando muy buen desempeño en el corto plazo (MAPE 1,8% en  $t+1$ ) pero una degradación marcada hacia los horizontes más lejanos (MAPE hasta 7,6% en  $t+6$ ).

En conjunto, ambos modelos confirman que predecir el precio del BTC es más confiable a 1-3 días que a 6-7 días, y que la elección entre uno u otro depende si buscamos simplicidad/estabilidad (regresión lineal) o mayor capacidad predictiva a corto plazo (red neuronal).